

Partie 1 : Fondamentaux du traitement automatique du langage naturel

Bassem Ben Hamed

ENETCOM – Université de Sfax

Février 2026

Section 1.1 — Panorama du NLP

- 1 Qu'est-ce que le NLP ? Défis fondamentaux
- 2 Tâches majeures du NLP
- 3 Brève introduction à l'IA
- 4 Modèles discriminatifs vs. génératifs
- 5 Évolution historique des modèles de langage
- 6 Des règles aux embeddings

Section 1.2 — Représentation et évaluation du texte

- 7 Fondamentaux de la tokenisation
- 8 Modèles d'espace vectoriel
- 9 Représentations creuses vs. denses
- 10 Similarité sémantique
- 11 Métriques d'évaluation (classification)
- 12 Métriques d'évaluation (génération)
- 13 Pratique : Lab 1

À la fin de cette session, vous serez capable de :

- ➊ **Définir** le traitement automatique du langage naturel et identifier ses défis fondamentaux.
- ➋ **Reconnaître** les tâches majeures du NLP et leurs applications concrètes.
- ➌ **Situer** le NLP dans le champ plus large de l'intelligence artificielle.
- ➍ **Distinguer** les approches de modélisation discriminative et générative.
- ➎ **Retracer** l'évolution historique des modèles de langage, des règles aux embeddings.
- ➏ **Comprendre** les stratégies de tokenisation et les représentations vectorielles.
- ➐ **Appliquer** les métriques d'évaluation adaptées aux différentes tâches NLP.

Section 1.1

Panorama du traitement automatique du langage naturel

Définition, défis, tâches et évolution historique


Qu'est-ce que le traitement automatique du langage naturel ?

Définition

Le NLP est un domaine à l'intersection de la **linguistique**, de l'**informatique** et de l'**intelligence artificielle**, qui vise à permettre aux machines de comprendre, interpréter et générer le langage humain.

Portée :

- **Compréhension** : extraire le sens d'un texte
- **Génération** : produire du langage naturel cohérent
- **Interaction** : systèmes de dialogue et conversationnels



Pourquoi le langage naturel est-il difficile ?

Ambiguïté

- **Lexicale** : « J'ai vu un avocat. »
(fruit ou professionnel du droit ?)
- **Syntaxique** : « J'ai vu l'homme avec le télescope. »
(qui a le télescope ?)
- **Sémantique** : « Le poulet est prêt à manger. »
(le poulet mange, ou on mange le poulet ?)

Dépendance au contexte

- Un même mot peut avoir un sens différent selon le texte environnant
- Nécessite des connaissances du monde et du bon sens

Variabilité

- Synonymes : « content » / « heureux » / « joyeux »
- Paraphrases, argot, fautes de frappe, abréviations
- Différences multilingues et interculturelles

Tâches majeures du NLP (1/2)

Classification de texte

Attribuer une étiquette à un texte.

« *Ce film était génial !* » → **Positif**

Applications : analyse de sentiments, détection de spam, catégorisation thématique.

Traduction automatique

Traduire un texte d'une langue à une autre.

« *The cat sat on the mat.* »

→ « *Le chat s'est assis sur le tapis.* »

Défis : ordre des mots, expressions idiomatiques, contexte culturel.

Reconnaissance d'entités nommées (NER)

Extraire des entités structurées du texte.

« *Apple* a été fondée par *Steve Jobs* à *Cupertino*. »

ORG PERSONNE LIEU

Tâches majeures du NLP (2/2)

Résumé de texte

Condenser un document en informations clés.

Extractif : sélectionner les phrases importantes.

Abstractif : générer un nouveau texte concis.

Applications : synthèses d'actualités, résumés de rapports.

Réponse aux questions

Répondre à des questions à partir d'un contexte ou de connaissances.

C : « Paris est la capitale de la France. »


Q : « Quelle est la capitale de la France ? »

R : « Paris »

Variantes : extractif, génératif, domaine ouvert.



Où se situe le NLP ? Le paysage de l'IA



Intelligence Artificielle

Machines simulant les capacités cognitives humaines : raisonnement, apprentissage, perception, langage.

Apprentissage Automatique (ML)


Systèmes qui **apprennent à partir des données** au lieu d'être explicitement programmés.

Apprentissage Profond (DL)

ML utilisant des **réseaux de neurones** à plusieurs couches. Alimente le NLP, la vision et la parole.

Le NLP se situe à l'intersection des trois, appliquant les techniques d'IA au **langage humain**.

L'apprentissage automatique en bref



Trois paradigmes d'apprentissage

- **Supervisé** : données étiquetées (entrée → sortie)
ex : détection de spam, NER
- **Non supervisé** : pas d'étiquettes, trouver la structure
ex : clustering, modélisation de sujets
- **Auto-supervisé** : étiquettes issues des données elles-mêmes
ex : prédire le mot suivant — utilisé par les LLMs !

Ingrédients clés

- **Données** : exemples d'entraînement
- **Modèle** : fonction paramétrée
- **Perte** : mesure l'erreur de prédiction
- **Optimiseur** : met à jour les paramètres (SGD, Adam)


Modèles discriminatifs vs. génératifs

Modèles discriminatifs

Apprennent la **frontière de décision** $P(y | x)$.

Étant donnée une entrée x , prédisent directement l'étiquette y .

- Régression logistique, SVM, BERT
- Objectif : *classification* / *compréhension*
- « À quelle classe cela appartient-il ? »




Modèles génératifs

Apprennent la **distribution des données** $P(x)$ ou $P(x, y)$.

Peuvent *générer* de nouvelles données similaires aux données d'entraînement.

- N-grammes, GPT, LLMs, GANs, VAEs
- Objectif : *génération* / *création*
- « Générer du texte qui ressemble à ceci. »




Discriminatif vs. génératif : perspective NLP


Aspect	Discriminatif	Génératif
Objectif	Prédire l'étiquette $P(y x)$	Modéliser la distribution $P(x)$
Tâches NLP	Classification, NER, sentiment	Traduction, résumé, dialogue
Modèles	BERT, SVM, Rég. logistique	GPT, T5, LLMs
Entraînement	Nécessite des données étiquetées	Peut utiliser du texte non étiqueté (auto-supervisé)
Sortie	Une étiquette de classe ou un tag	Une nouvelle séquence de texte

La tendance moderne

Les LLMs modernes (GPT-4, Claude, LLaMA) sont des modèles **génératifs** qui peuvent aussi résoudre des tâches **discriminatives** via le prompting — la frontière s'estompe.



Évolution historique des modèles de langage



Observation clé

Chaque ère a répondu aux limitations de la précédente, passant progressivement des **règles manuelles** aux **représentations apprises**.

Ère 1 : systèmes à base de règles (1950–1980)

Approche :

- Les linguistes écrivent manuellement des règles grammaticales
- Les systèmes experts encodent la connaissance du domaine en règles si-alors
- Grammaires formelles (CFG, regex) pour l'analyse syntaxique

Exemples :

- **ELIZA** (1966) : chatbot par correspondance de motifs
- Systèmes de traduction à base de règles
- Correcteurs orthographiques par dictionnaire

Limitations

- Ne passe pas à l'échelle pour un langage complexe
- Fragile : échoue sur les motifs inconnus
- Coût de maintenance élevé
- Gère mal l'ambiguïté
- Spécifique à une langue

SI le motif correspond



ALORS appliquer la règle

Ére 2 : NLP statistique — N-grammes et HMMs (1990–2000)

Modèles de langage N-grammes

Modéliser la probabilité d'un mot étant donnés les $n-1$ mots précédents :

$$P(w_n \mid w_1, \dots, w_{n-1}) \approx P(w_n \mid w_{n-k}, \dots, w_{n-1})$$

- **Unigramme** : $P(w)$ — fréquence des mots
- **Bigramme** : $P(w_n \mid w_{n-1})$
- **Trigramme** : $P(w_n \mid w_{n-2}, w_{n-1})$

Modèles de Markov cachés

- Séquence d'états cachés générant des observations
- Utilisés pour l'étiquetage POS, la reconnaissance vocale
- Algorithme de Viterbi pour le décodage

Limitations

- Rareté des données pour les n-grammes d'ordre élevé
- Fenêtre de contexte limitée
- Pas de compréhension sémantique

Ére 2 : Bag-of-Words et TF-IDF

Bag-of-Words (BoW)

Représenter un document comme un **vecteur de fréquences de mots**, en ignorant l'ordre des mots.

« le chat dort sur le tapis » → [2, 1, 1, 1, 1]

TF-IDF

Pondérer les mots par leur **importance** :

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \log \frac{N}{\text{df}(t)}$$

- Mots courants (« le ») → poids faible
- Mots rares et distinctifs → poids élevé

Propriétés

- Simple et efficace pour de nombreuses tâches
- Fonctionne bien pour la classification et la recherche
- Fondation des premiers moteurs de recherche

Limitations


- Pas d'ordre des mots ni de grammaire
- Pas de similarité sémantique
- Vecteurs creux de haute dimension

Ére 3 : Word Embeddings — Word2Vec (Mikolov et al., 2013)


Idée clé

« On connaît un mot par la compagnie qu'il fréquente. » — J.R. Firth, 1957. Apprendre des **représentations vectorielles denses** où les mots sémantiquement similaires sont proches dans l'espace vectoriel.

CBOW (Continuous Bag-of-Words)



Skip-gram



Ére 3 : GloVe, FastText et arithmétique vectorielle

GloVe (Pennington et al., 2014)

- Factorisation de la matrice de co-occurrence **globale**
- Combine méthodes par comptage et prédictives


FastText (Bojanowski et al., 2017)

- Étend Word2Vec avec l'info **sous-mot**
- « malheureux » → <ma, mal, alh, ..., eux>
- Gère les mots hors vocabulaire ; meilleur pour les langues morphologiquement riches

Arithmétique vectorielle

Les embeddings capturent des **relations sémantiques** :

$$\vec{\text{roi}} - \vec{\text{homme}} + \vec{\text{femme}} \approx \vec{\text{reine}}$$



Résumé : des règles aux embeddings

Approche	Représentation	Sémantique	Scalabilité	Ére
Règles	Symbolique	Manuelle	Faible	1950
N-grammes / BoW	Par comptage	✗ Non	Moyenne	1990
TF-IDF	Comptage pond.	Partielle	Moyenne	1990
Word2Vec	Vecteurs denses	✓ Oui	Élevée	2013
GloVe	Vecteurs denses	✓ Oui	Élevée	2014
FastText	Vecteurs sous-mot	✓ Oui	Élevée	2017

Perspectives

Ces embeddings sont **statiques** — un mot reçoit toujours le même vecteur quel que soit le contexte. Suite : **représentations contextuelles** (RNNs, Transformers) où un même mot reçoit des vecteurs différents selon le contexte.

Suite : Section 1.2

Représentation et évaluation du texte

- Comment tokeniser le texte pour les modèles
- Modèles d'espace vectoriel en détail
- Mesures de similarité sémantique
- Métriques d'évaluation pour les tâches NLP

Plus tard : Partie 2

Des RNNs aux Transformers

- Modèles séquentiels (LSTM, GRU)
- Le mécanisme d'attention
- Architecture Transformer
- BERT, GPT et au-delà

Embeddings statiques

Embeddings contextuels

Grands modèles de langage

Section 1.2

Représentation et évaluation du texte

Représenter et mesurer le langage


Section 1.2 — Objectifs d'apprentissage

- ❶ **Comprendre** les méthodes de tokenisation et leurs compromis.
- ❷ **Maîtriser** les modèles d'espace vectoriel et les représentations distribuées.
- ❸ **Mesurer** la similarité sémantique entre textes avec différentes métriques.
- ❹ **Évaluer** les modèles NLP avec des métriques adaptées à la tâche :
 - Classification : Accuracy, Precision, Recall, F1-Score
 - Modélisation du langage : Perplexité
 - Génération : BLEU, ROUGE

Tokenisation : la première étape critique

Pourquoi tokeniser ?

Les modèles ne peuvent pas traiter du texte brut directement. La tokenisation convertit le texte en **unités discrètes** qui peuvent être représentées numériquement.



Tokenisation : niveaux de granularité

Niveau	Exemple	Avantages	Inconvénients
Mot	« J'aime le NLP » → [J', aime, le, NLP]	Intuitif, préserve le sens	Grand vocabulaire, problème OOV
Caractère	« NLP » → [N, L, P]	Petit vocabulaire, pas d'OOV	Séquences longues, perd la sémantique
Sous-mot (BPE)	« malheureux » → [mal, heur, eux]	Meilleur compromis, gère l'OOV	Nécessite un entraînement

Note

Les LLMs modernes (GPT, BERT, LLaMA) utilisent tous la **tokenisation sous-mot**. Nous aborderons BPE, WordPiece et SentencePiece en détail dans la Partie 2.

Modèles d'espace vectoriel

Principe fondamental


Représenter chaque document (ou mot) comme un **vecteur** dans un espace à N dimensions.

Hypothèses clés :

- Chaque dimension = une caractéristique (mot ou feature apprise)
- **Documents similaires** → vecteurs proches
- **Documents différents** → vecteurs éloignés

Hypothèse distributionnelle

Les mots apparaissant dans des contextes similaires ont des significations similaires.



Représentations creuses vs. denses

Creuses (BoW / TF-IDF)

$$\vec{v} = [0, 0, 3, 0, 0, 1, 0, \dots, 0]$$

- Dimension = taille du vocabulaire (10K–100K+)
- La plupart des valeurs sont nulles
- Pas de généralisation sémantique

Denses (Embeddings)

$$\vec{v} = [0,23, -0,45, 0,12, 0,87, \dots]$$

- Dimension = 50–300 (Word2Vec) ou 768+ (Transformers)
- Toutes les valeurs sont non nulles
- Capture les relations sémantiques

Propriété	Creuse	Dense
Dimensionnalité	Très élevée (10K+)	Faible (50–4096)
Capture sémantique	✗ Non	✓ Oui
Généralisation	Faible	Bonne
Interprétabilité	Élevée	Faible

Mesurer la similarité sémantique

Similarité cosinus (la plus courante)

$$\cos(\theta) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \times \|\vec{B}\|}$$

- Intervalle : $[-1, 1]$; 1 = direction identique
- **Invariante à la magnitude**
- Préférée pour la similarité textuelle

Distance euclidienne

$$d(\vec{A}, \vec{B}) = \sqrt{\sum_i (A_i - B_i)^2}$$

Sensible à la magnitude des vecteurs.

Produit scalaire

$$\vec{A} \cdot \vec{B} = \sum_i A_i \times B_i$$

Rapide mais affecté par la magnitude.

Exemple


$\text{sim}(\text{« roi »}, \text{« reine »}) = 0,85$

$\text{sim}(\text{« roi »}, \text{« voiture »}) = 0,12$

Haute similarité → sémantiquement liés.

Règle générale : cosinus pour le texte, euclidienne pour le clustering, produit scalaire pour la vitesse.

Applications de la similarité sémantique



Le pattern de récupération

requête $\xrightarrow{\text{embed}}$ $\vec{q}$ $\xrightarrow{\text{plus proches voisins}}$ Top- k documents similaires

Ce pattern est le fondement de la **génération augmentée par récupération (RAG)**, abordée en Partie 4.

Métriques d'évaluation : pourquoi mesurer ?

Motivation

« *Ce qui ne se mesure pas ne s'améliore pas.* »

L'évaluation permet de :

- Comparer les modèles objectivement
- Suivre les progrès dans le temps
- Identifier les faiblesses
- Prendre des décisions de déploiement

Deux familles de métriques

Métriques de classification (discriminatif)

- Accuracy, Precision, Recall, F1

Métriques de génération (génératif)

- Perplexité (modélisation du langage)
- BLEU (traduction)
- ROUGE (résumé)

Important

Aucune métrique seule ne raconte toute l'histoire. Utilisez toujours **plusieurs métriques** et considérez le contexte de la tâche.

Métriques de classification

Matrice de confusion

	Préd +	Préd -
Vrai +	TP	FN
Vrai -	FP	TN

Formules

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1-Score

Moyenne harmonique de la Precision et du Recall :

$$F_1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Attention : déséquilibre des classes


Avec 95% d'échantillons négatifs, prédire « toujours négatif » donne **95% d'accuracy** — mais c'est inutile !
→ Vérifiez toujours P, R et F1.

Precision vs. Recall : le compromis

Analogie de la bibliothèque

Precision : parmi les livres que j'ai trouvés, combien sont pertinents ?

Recall : parmi tous les livres pertinents, combien ai-je trouvés ?



Quand privilégier lequel ?

Haute Precision :

- Détection de spam (ne pas perdre de vrais emails)
- Recherche de documents juridiques

Haut Recall :

- Diagnostic médical (ne pas manquer de maladies)
- Détection de fraude

Équilibré (F1) :

- La plupart des tâches NLP générales (NER, classification)

Perplexité : évaluer les modèles de langage

Définition

La perplexité mesure à quel point un modèle de langage prédit bien une séquence :


$$\text{PPL} = 2^{-\frac{1}{N} \sum_{i=1}^N \log_2 p(w_i \mid w_1, \dots, w_{i-1})}$$

Interprétation

- PPL de $k \approx$ le modèle hésite entre k mots
- **Plus basse** = meilleur modèle
- PPL = 1 signifie prédiction parfaite

Limitation

Faible PPL $\neq$ texte de haute qualité. Un modèle peut avoir une faible PPL mais produire du texte répétitif.



Objectif

Bilingual **E**valuation **U**nderstudy — principalement pour la **traduction automatique**.

Fonctionnement :

- 1 Calculer la **précision n-gramme modifiée** entre la sortie et la/les référence(s)
- 2 Appliquer une **pénalité de brièveté** (BP)
- 3 Combiner :

$$\text{BLEU} = \text{BP} \cdot \exp\left(\sum_{n=1}^N \frac{1}{N} \log p_n\right)$$

Exemple

Réf : « Le chat s'est assis sur le tapis »

Sortie : « Le chat sur le tapis »

Précision unigramme : $5/5 = 1,0$

Précision bigramme : $2/4 = 0,5$

→ Pénalisé pour le mot manquant « s'est assis »

Limitations

- Pas de compréhension sémantique
- Sensible aux paraphrases
- Référence unique peu fiable

Score ROUGE (Lin, 2004)

Objectif

Recall-Oriented Understudy for Gisting Evaluation — principalement pour le **résumé**.

ROUGE-N

Chevauchement de n-grammes entre la sortie et la référence :

$$\text{ROUGE-N} = \frac{\sum \text{n-grammes correspondants}}{\sum \text{n-grammes dans la référence}}$$

- **ROUGE-1** : chevauchement unigramme
- **ROUGE-2** : chevauchement bigramme

ROUGE-L

Basé sur la **plus longue sous-séquence commune** (LCS).

- Capture la structure au niveau de la phrase
- Pas besoin de correspondances contiguës

BLEU vs. ROUGE

BLEU : orienté précision

« Quelle part de la sortie est correcte ? »

ROUGE : orienté rappel

« Quelle part de la référence est capturée ? »

Métriques d'évaluation : résumé

Métrique	Tâche	Mesure	Intervalle
Accuracy	Classification	Justesse globale	$[0, 1]$
Precision	Classification	Pertinence des prédictions	$[0, 1]$
Recall	Classification	Complétude de la détection	$[0, 1]$
F1-Score	Classification	Équilibre P et R	$[0, 1]$
Perplexité	Mod. du langage	Incertitude du modèle	$[1, \infty)$
BLEU	Traduction	Précision n-gramme	$[0, 1]$
ROUGE	Résumé	Rappel n-gramme	$[0, 1]$

Dans les parties suivantes

Métriques modernes : **BERTScore**, **LLM-as-a-Judge**, **RAGAS** (évaluation RAG), **MT-Bench** (suivi d'instructions).

Ce que nous avons couvert

- ✓ Définition, défis et tâches du NLP
- ✓ Paysage de l'IA et discriminatif vs. génératif
- ✓ Évolution : règles → statistiques → embeddings
- ✓ Tokenisation et modèles d'espace vectoriel
- ✓ Métriques de similarité
- ✓ Métriques d'évaluation

Tâches du Lab 1

- ➊ Prétraitement de texte et tokenisation
- ➋ Construire un classifieur TF-IDF
- ➌ Entraîner Word2Vec sur un corpus
- ➍ Explorer les analogies dans l'espace vectoriel
- ➎ Comparer approches classiques et modernes

Outils

Python, NLTK, scikit-learn, Gensim

Passons au code !