

# Scaling Laws – Kaplan & Chinchilla

---

## Kaplan (2020) – OpenAI

$$L \propto \left(\frac{N}{N_c}\right)^{-\alpha_N} + \left(\frac{D}{D_c}\right)^{-\alpha_D}$$

### Variables :

- $L$  – loss (erreur du modèle, plus c'est bas mieux c'est)
- $N$  – nombre de paramètres du modèle (ex: 7B, 70B)
- $N_c$  – seuil critique de paramètres (constante empirique)
- $D$  – nombre de tokens d'entraînement
- $D_c$  – seuil critique de tokens (constante empirique)
- $\alpha_N \approx 0.076$  – exposant pour les paramètres
- $\alpha_D \approx 0.095$  – exposant pour les données

**Règle pratique :**  $D \propto N^{0.74} \rightarrow$  priorité au modèle, moins de données

GPT-3 : 175B paramètres, ~300B tokens  $\rightarrow$  **sous-entraîné selon Chinchilla**

---

## Chinchilla (2022) – DeepMind

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta}$$

### Variables :

- $L(N, D)$  – loss finale fonction de N et D
- $E$  – entropie irréductible (limite théorique, incompressible)
- $A, B$  – constantes empiriques ajustées sur les expériences
- $\alpha \approx 0.34$  – sensibilité de la loss aux paramètres
- $\beta \approx 0.28$  – sensibilité de la loss aux données
- $N$  – nombre de paramètres
- $D$  – nombre de tokens

**Règle pratique :**  $D = 20 \times N \rightarrow$  équilibre modèle et données

Llama 3 8B : ~8B paramètres  $\rightarrow$  entraîné sur **15T tokens** (bien au delà de Chinchilla, volontairement)

---

## Comparaison

|                 | Kaplan               | Chinchilla                    |
|-----------------|----------------------|-------------------------------|
| Année           | 2020                 | 2022                          |
| Formule clé     | $D \propto N^{0.74}$ | $D = 20 \times N$             |
| Priorité        | Taille du modèle     | Équilibre N et D              |
| Conclusion      | Plus grand = mieux   | Données autant que paramètres |
| Modèles issus   | GPT-3                | Llama, Mistral, Gemma         |
| Erreur corrigée | –                    | GPT-3 était sous-entraîné     |

Intuition finale

$L$   
erreur

=

$E$   
limite humaine

+

$\frac{A}{N^\alpha}$   
manque de paramètres

+

$\frac{B}{D^\beta}$   
manque de données

Pour réduire la loss : il faut réduire **les deux termes ensemble** – ni trop de paramètres sans données, ni trop de données sans capacité du modèle.